澄灯 LumaRV

面向控制板试产与返修的语境感知调试系统

摘要

控制板试产与返修中，工程师需要临时复核输出、局部修改参数，并保留其他状态。澄灯 LumaRV 围绕这一流程设计中文语境与工具分支：识别操作与限制，检查参数和能力，再执行并读回。系统以现有开发板自身演示 LED 位保持、PWM 占空比设置、结温与周期计数读取，以及 CPU 基础计算复核。语义分支使用 25014 条文本训练，将字符短语记忆、全局与首尾位置特征、受约束工具残差结合，部署学习权重 197816B。五级 RV32IM 负责调度，4MAC 编码器与 8MAC 位置语义侧核分工，128KiB 常驻权重缓存减少重复搬运。40.5MHz 下，指定中文 PWM 请求的完整模型计算为 74.567ms，比同镜像软件路径快 13.40 倍；CoreMark 为 2.031490/MHz。四批用户原文实板结果为 24/25、25/25、25/25、25/25，其中一条 81 字节输入按长度拒绝。

第一部分 作品概述

1.1 功能与特性

系统接受中文请求，读取 FPGA 结温和周期计数，设置 LED 掩码、单灯状态及 1kHz PWM 占空比，并执行 CoreMark。单灯操作保留其他位，写操作返回寄存器读回值。明确语法、语境分支和完整编码器按请求分工。模型给出候选动作后，固件检查工具、参数与硬件能力；不支持、含多个动作或参数越界的请求不进入外设写操作。

1.2 应用领域

应用面向电子控制板试产与返修中的临时复测。固定流程仍由按钮或脚本完成，中文入口用于表达局部操作和限制：只关闭 LED0 而保留其他位，设置合法 PWM 占空比，再核对寄存器读回。操作者也可查询控制器结温、计数值，或运行 CPU 基础计算检查。原型检查的是开发板自身，不包含外部待测板测量；现有结果用于验证交互与执行链路，尚未测得工厂操作效率或整板验收覆盖率。

1.3 主要技术特点

语义计算结合双层 d64 字节编码器、Unicode 字符短语记忆，以及全局 1024 维、首尾各 512 维的位置特征。2048→64→16 位置语义头处理语境和工具信息，70→5 受约束残差修正合法工具混淆。4MAC 计算 INT4/INT8 编码器，8MAC 计算 INT8 位置语义头，并使用 128KiB 常驻权重缓存和非零特征组跳过。CPU 执行残差与工具许可。五级 RV32IM、两路组相联 I/D Cache、分支预测和异常中断提供运行基础。

1.4 主要性能指标

指标	结果
主频 / CPU 性能	40.5MHz；2.031490 CoreMark/MHz
指定中文 PWM 模型	74.567ms；同镜像加速 13.40 倍
轻量路径往返中位数	1.40～5.16ms；4 句各 n=10
学习权重 / 存储	197816B；SRAM512KiB + 缓存 128KiB
逻辑资源	19456LUT、19116FF、292.5DRM、33APM

1.5 主要创新点

（1）面向中文设备操作设计语境与工具分支，将字符短语记忆和首尾位置特征结合，用 25014 条文本训练。

（2）将 64 维隐层与六类编码器输出组成 70→5 受约束残差，修正合法工具之间的混淆。

（3）按分支配置 4MAC 与 8MAC，结合常驻权重缓存、非零特征组跳过，使指定 PWM 请求的完整模型计算加速 13.40 倍。

1.6 设计流程

确定控制器操作和参数范围，建立语料及参考模型；训练语境、工具分支并导出整数参数；实现 CPU、存储与乘加加速器，对照 C 参考完成仿真；使用 PDS 综合、布局布线并分析时序；在开发板运行中文指令、寄存器读回和 CoreMark，最后制作交互界面与分层动画。

第二部分 系统组成及功能说明

2.1 整体介绍

控制板试产或返修时，固定测试完成后仍可能需要临时复核某个输出。操作者逐条输入请求：先读取片内结温，再只关闭 LED0、保留其他位，随后设置 PWM 占空比并核对读回。澄灯 LumaRV 判断操作与执行语境，CPU 检查参数和硬件能力，再访问外设。电脑控制台通过 UART 输入文字、汇总本次结果。



图 1 控制板临时复测的交互与读回流程

图 1 以开发板自身为复测对象，连接输出设置、状态读取、CPU 基础计算检查和操作记录。“只关闭 LED0，其他 LED 保持不变”检验局部操作；请求

改变固定 PWM 频率时拒绝执行。每句话只执行一个工具，操作者根据返回结果继续下一步。该流程补充固定测试，不替代工装测量或整板合格判定。

2.2 硬件系统介绍

2.2.1 硬件整体介绍

硬件平台采用 PG2L200H 及开发板现有接口。27MHz 输入时钟经 GPLL 生成 40.5MHz，按键 KEY0 用于系统复位。UART、片内温度采样、GPIO、PWM 和 32 位周期计数器通过 MMIO 与 CPU 连接。主 SRAM 容量 512KiB，其中 CPU 占 128KiB、AI 工作区占 384KiB；位置语义头另有 128KiB 权重缓存。

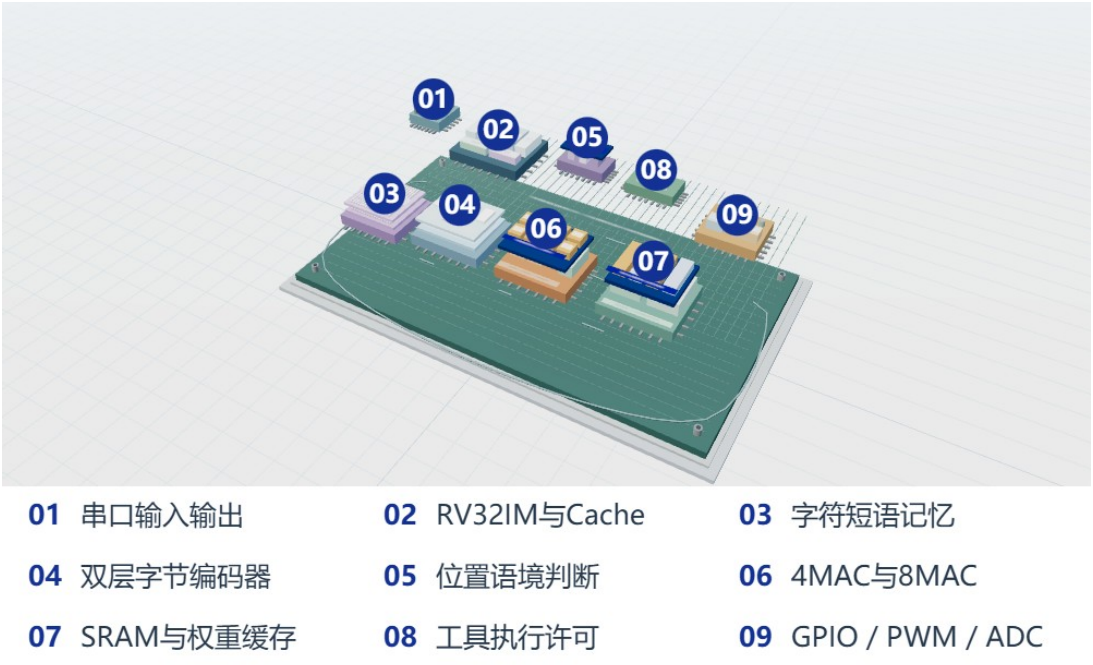


图 2 模块分层与片上计算结构

三维图将计算、存储、语境判断和外设分层，交互页面可旋转、展开模块，并按一次 PWM 请求显示处理流程。它表示逻辑连接，模块位置不对应布局布线后的器件坐标。

2.2.2 机械设计介绍

系统使用厂家开发板、配套电源、USB 串口和 JTAG 线缆。展示时将板卡与电脑界面并排摆放，便于同时观察 LED 变化与操作结果。

2.2.3 电路各模块介绍

模块	关键输入	关键输出
CPU 与 Cache	时钟、复位、访存响应	指令/数据地址、写数据、提交 PC
共享 DMA	计算任务、地址与读写请求	数据响应、任务归属、错误状态
4MAC 编码器	INT4 权重、INT8 激活	INT32 累加值、任务状态
8MAC 位置语义头	INT8 特征、常驻权重	INT32 语义分数、完成状态
UART 与外设	串口输入、按键、ADC 采样	串口输出、LED、PWM 寄存器值

PWM 固定为 1kHz，通过周期与高电平计数设置占空比。LED 支持整体掩码和单灯置位、清位。写操作完成后再次读取寄存器，核对请求值与保存值；该读回未测量外部引脚波形。

2.3 软件系统介绍

2.3.1 软件整体介绍

控制台提供 AI 识别、快速控制和 CPU 自检三个入口。AI 入口先配置完整模型路径，收到板卡确认后再发送中文请求；快速控制处理明确设备语法；CPU 自检运行 CoreMark 并显示 CRC 与成绩。请求与返回逐条对应，上一条就绪后再发送下一条。

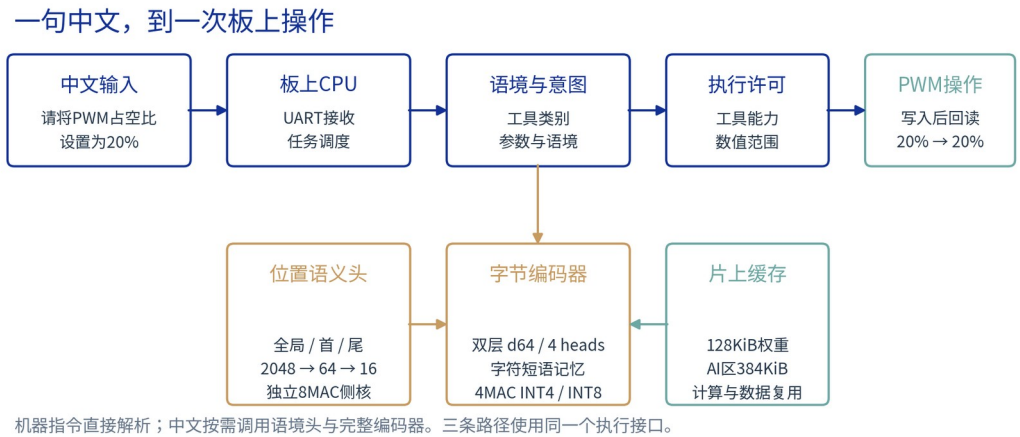


图 3 中文请求的处理流程

处理路径分为三类：机器指令直接解析；自然语言先判断语境，再由明确语法提取工具和参数；未命中明确语法时运行完整编码器。AI 入口还可要求本次请求运行完整模型。语境判断拒绝的请求不会被后续工具解析重新放行。三类路径共用参数、能力检查与执行接口。

2.3.2 模型设计与训练

AI 任务分为语境判断和工具识别：一句话是在要求执行，还是解释、假设、引用或否定；若可执行，再识别温度、PWM、CoreMark、计数器或 LED。模型同时保留拒绝类别，参数由固件解析。与图像检测输出物体类别和位置不同，本作品围绕中文中的动作、条件和设备参数设计。

参考基础	本项目设计
Needle 低比特工具调用与字符短语记忆	板卡五类操作、中文语境分支与训练语料
通用 Transformer 编码器结构	双层 d64 整数运行时、首尾位置特征与 70→5 工具残差
RISC-V 指令集	五级 CPU、Cache、异常中断与外设实现
整数乘加与同步 RAM 方法	4MAC 编码器、8MAC 位置语义侧核、常驻权重缓存与零组跳过
MASSIVE 中文语料	选择 2800 条域外请求，按设备能力重新标注

双层 d64 字节编码器包含四个注意力头和学习型 2/3-gram 记忆。位置分支汇总全局 1024 维、首尾各 512 维特征，输入 2048→64→16 位置语义头。64 维隐层与六类编码器输出组成 70 维向量，70→5 受约束残差修正合法工具之间的判断；这部分由 CPU 标量执行。

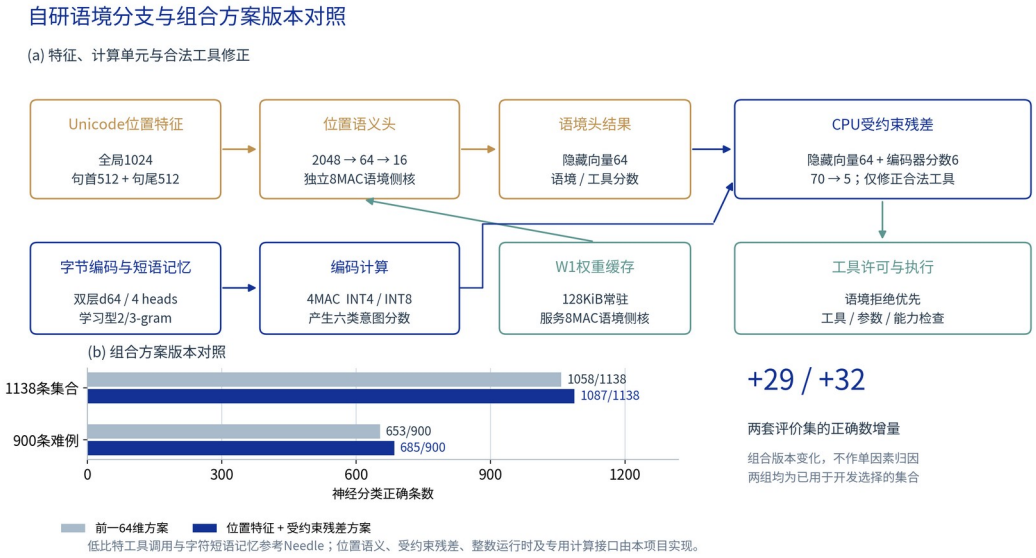


图 4 自研语义分支与组合版本对照

与前一 64 维候选相比，当前组合版本在 1138 条集合的神经正确数由 1058 增至 1087，在 900 条难例中由 653 增至 685。训练与结构同时发生调整，这组数字说明组合版本的变化，不能单独归因于某一个模块。

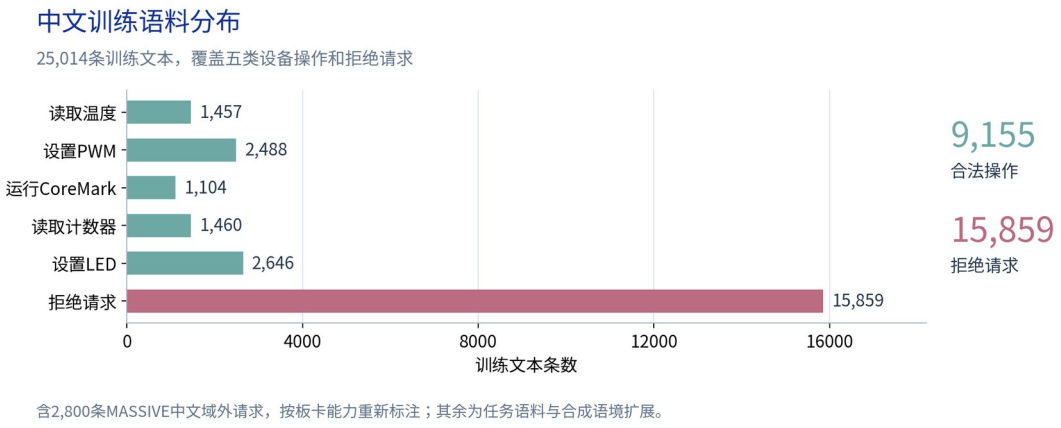


图 5 语境与工具分支的训练文本分布

语境与工具分支共使用 25014 条训练文本。合法操作 9155 条，包括温度 1457、PWM2488、CoreMark1104、计数器 1460 和 LED2646 条；拒绝请求 15859 条，覆盖解释、假设、引用、否定、多动作、越界能力等表达。语料结合任务样本与合成语境扩展，并选取 2800 条 MASSIVE 中文域外请求，按本板卡能力重新标注。四批用户指令用于回归，不是全部训练文本。

模型在服务器训练，学习权重 197816B，导出为 C 头文件和定点常量后编入固件。4MAC 编码器采用 INT4 权重与 INT8 激活；8MAC 位置语义头采用 INT8 权重，第一层权重驻留 128KiB 缓存，并跳过全零特征组。两类引擎均使用 INT32 累加。CPU 继续执行残差、参数解析与工具许可。

软件模块	输入	输出
输入处理	UTF-8 文本、长度及帧校验	单条请求或输入错误
语境与工具模型	字符、位置特征及编码向量	语境判断、六类分数
参数与许可	原文、工具候选、硬件能力	工具、参数及操作类型
执行与显示	允许执行的请求	实际值、读回结果、计时及就绪

第三部分 完成情况及性能参数

3.1 整体介绍

开发板已完成中文请求、语义计算、LED/PWM 寄存器访问及 CPU 基准运行。临时复测演示检查开发板自身：观察 LED 位保持，核对 PWM 请求值与读回值，读取 FPGA 结温和周期计数，执行 CoreMark 基础计算复核。现有记录不用于判定外接产品质量或自动定位故障。



图 6 系统全貌照片待插入

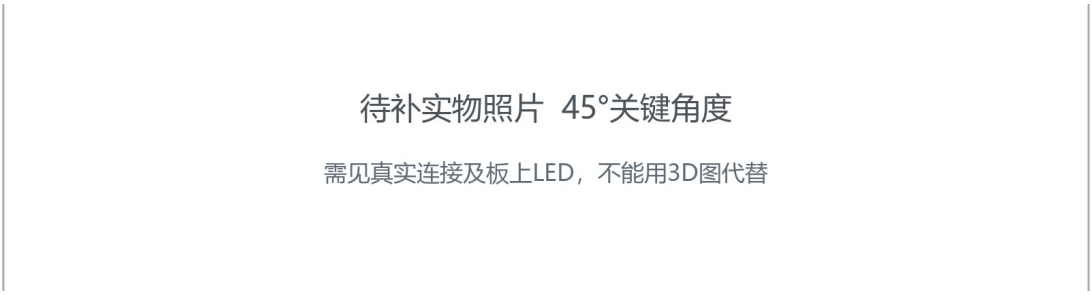


图 7 板卡与连接细节照片待插入

3.2 工程成果

3.2.1 机械成果

采用开发板现有结构与连接件，展示机位以看清板卡、线缆和用户 LED 为准。

3.2.2 电路成果

已实现 CPU、Cache、主存、权重缓存、两个乘加计算单元及板载外设 CPU 运行程序和模型调度，计算单元通过 DMA 访问数据。综合结果为 19456LUT、19116FF、292.5 个 DRM36 等效单元和 33 个 APM。

3.2.3 软件成果

控制台逐条显示模型是否参与、执行工具、参数和读回值。图 8 中的中文 PWM 请求要求占空比 20%，读回 20%，周期 40500、高电平 8100、使能为 1；这些字段来自实板寄存器。

中文PWM指令的处理结果

输入	请将PWM占空比设置为20%。
模型与工具	设置PWM / set_pwm
模型耗时	74.567 ms
参数与读回	请求 20% 读回 20% 一致
PWM寄存器	周期 40500 高电平 8100 使能 1

图 8 中文 PWM 请求的计算与寄存器读回结果

3.3 特性成果

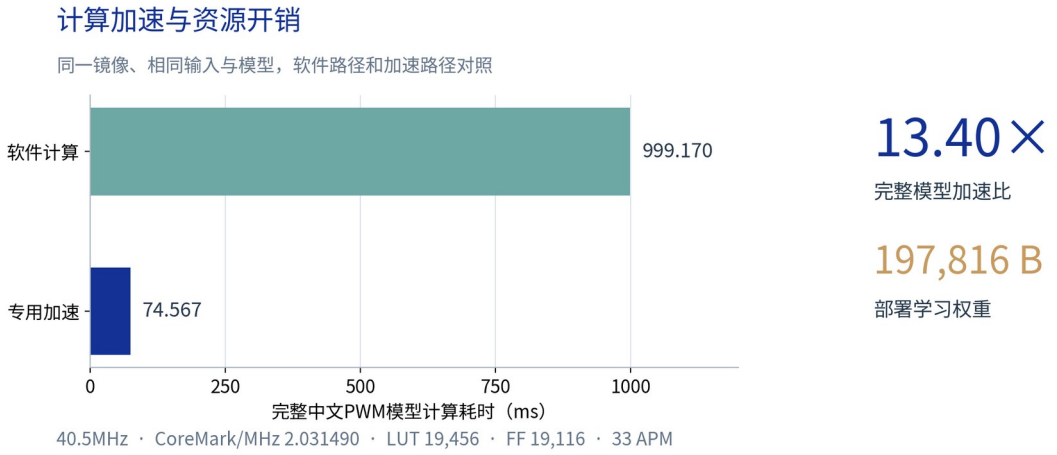


图 9 指定中文 PWM 请求的完整模型软件与加速路径

同一固件、相同中文 PWM 输入下，完整模型的软件路径为 40466391 周期加速路径为 3019968 周期，耗时由 999.170ms 降至 74.567ms，加速 13.39961 倍。两路径比较的编码器、语境、工具和残差分数一致。该请求通过 AI 入口运行完整模型；74.567ms 是这一输入的模型计算时间。

计时对象	实测结果	范围
指定中文 PWM 完整模型	74.567ms	板上计算，不含串口往返与工具执行
机器语法 / 仅语境分支	1.40～5.16ms	4 条固定输入，各 10 次原生 UART 往返中位数；含 USB 与主机调度
CPU 自检	14.58517242～14.58517336s	1200 迭代 CoreMark 算法计时

40.5MHz 下，15 次 1200 迭代 CoreMark 运行均通过五项 CRC，耗时 14.58517242 ～ 14.58517336 秒，约 2.031490 CoreMark/MHz 、 0.004229 CoreMark/LUT。慢、快工艺角的建立与保持检查均通过；setup 裕量分别为 1.901ns 和 11.214ns，hold 裕量为 0.147ns 和 0.102ns。此结果对应 40.5MHz 工作点。

两套开发评价集的神经分类与混合系统结果见表。1138 条集合含 196 条合法请求和 942 条拒绝请求；900 条难例含 200 条合法请求和 700 条拒绝请求。两组均已用于开发选择，结果用于分析该任务上的表现。

评价集	神经分类正确	误接受	误拒绝	合法工具错分
1138 条	1087/1138（95.52%）	50	0	1
900 条难例	685/900（76.11%）	190	24	1

1138 条集合中 195/196 条合法请求分类正确，另 1 条将 CoreMark 错分为温度；900 条难例中 175/200 条合法请求分类正确，24 条被拒绝，另 1 条将计数器错分为温度。合法工具之间的错分与误拒绝分别统计。

默认混合路径的正确数分别为 1135/1138 和 884/900，其中合法请求为 193/196、184/200。这两套开发集合中，执行许可均未放行应拒绝请求。系统判断同时使用语境、语法和参数检查，结果不计作原始神经分类准确率。

四批用户原文的实板结果依次为 24/25、25/25、25/25、25/25。其中一条 81 字节输入触发长度限制；64 字节范围内 98/99 符合预期。“我想知道这颗 CPU 的 CoreMark 成绩。”被语境分支保守拒绝，未启动基准。此次回归中拒绝请求

前后的 LED 与 PWM 状态保持一致。使用模拟 DOM 的生产网页程序通过真实 UART 完成 AI PWM、LED 和 CPU 自检 12 个事务；另有 250 项网页状态机模拟测试。

CPU 运行期间通过 PMU 计数周期、退役指令和缓存事件。CoreMark 采样区间为 590699592 周期、退役 364493010 条，CPI 约 1.621；基准成绩采用 590699515 算法周期。现有 ILA 波形来自较早版本，本报告的当前 CPU 分析使用上述 PMU 结果。

第四部分 总结

4.1 可扩展之处

接入其他控制板时，需要按型号定义工具、参数和接口，并配合工装完成外部电压、电流与输出波形测量。应用评价可比较完成同一复测任务的操作时间、首次正确率和人工干预次数；这些收益尚待实测。模型方面继续考察独立来源的否定、多动作与工具错分，硬件方面补充本版关键算法 ILA 和外部 PWM 测量。

4.2 心得体会

这个项目的难点在于让模型判断、计算资源和硬件动作配合起来。训练过程中，单纯增加隐藏层或拆分专家没有持续提高结果；加入首尾位置特征等设计后，语境与工具判断有所改善。小型残差用于纠正合法工具之间的混淆，额外存储开销较小。

部署时，模型数组能放进 RAM 还不够。权重的读法、端口时序和零值特征的处理都会影响综合结果。将第一层权重常驻缓存，并按同步 RAM 组织访问后，LUT 和触发器开销明显降低，计算结果与参考保持一致。

交互设计也影响使用体验。把所有请求都送入完整模型会增加等待，直接语法、语境判断和完整编码器分开处理后，界面既能快速控制，也能展示自然语言模型。执行后再读回寄存器，可以及时发现参数或操作结果是否符合预期。

后续仍需要用更多独立语料考察否定、多动作和能力边界，而不是只增加熟悉句式。

第五部分 参考文献

[1] RISC-V International. RISC-V Instruction Set Manual[EB/OL]. https://docs.riscv.org/reference/isa/.

[2] EEMBC. CoreMark benchmark[CP/OL]. https://github.com/eembc/coremark.

[3] Cactus Compute. Needle source repository[CP/OL]. https://github.com/cactus-compute/needle.

[4] Home Assistant. Intents architecture[EB/OL]. https://contributors.home-assistant.io/core/internals/intents/.

[5] FitzGerald J, Hench C, Peris C, et al. MASSIVE: A 1M-Example Multilingual Natural Language Understanding Dataset with 51 Typologically-Diverse Languages[EB/OL]. 2022. https://arxiv.org/abs/2204.08582.

[6] 紫光同创. 2026 年 FPGA 创新设计赛道紫光同创选题指南[Z]. 2026.

[7] 紫光同创. Pango Design Suite User Guide 及 Fabric Configuration User Guide[Z]. PDS 2022.2-SP6.4.

[8] 开发板厂家. MES2L676-200HP 硬件使用手册[Z]. v1.2.

[9] Three.js contributors. Three.js[CP/OL]. https://github.com/mrdoob/three.js.

[10] NI. Electronics Manufacturing Test Solutions[EB/OL]. https://www.ni.com/content/dam/web/pdfs/electronics_manufacturing_test_solutions_brochure.pdf.

[11] Raspberry Pi. Turn text input into actions with Needle[EB/OL]. https://www.raspberrypi.com/news/turn-text-input-into-actions-with-needle-a-14mb-function-calling-llm/.